Лабораторна робота №2. Методи класифікації

Виконав студент групи КМ-91мп

Галета М.С.

Завдання на лабораторну роботу

1. Обрати відповідний файл з даними.
2. Збудувати дерево прийняття рішень для визначення значення цільової характеристики (останній стовпчик) на основі вхідних аргументів (інші стовпчики). Записи у файлі з даними потрібно розділити на навчальну та відкладену вибірки.
3. Параметри дерева та алгоритм його побудови обрати самостійно. Дерево не повинно бути занадто гіллястим, за потреби використовуйте процедуру обрізання. Використовувати бібліотечні функції забороняється.
4. Оцінити якість збудованого дерева за допомогою методу відкладеної вибірки. Надати графічне порівняння результатів, отриманих за допомогою застосування збудованого дерева прийняття рішень до відкладеної вибірки, із фактичними значеннями цільової характеристики.
5. Застосувати для визначення цільової характеристики на даних відкладеної вибірки метод k найближчих сусідів. Визначити кількість сусідів, при якій метод дає найкращу точність.
6. Порівняти результати з п.п. 4 та 5.

In [1]:

```
import numpy as np
import math
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split

%matplotlib inline
```

Зчитування датасету та його розбиття на тренувальну та відкладену вибірки

In [2]:

```
df = pd.read_csv('MP-04-Galeta.csv', sep=';', names=['x1', 'x2', 'x3', 'x4', 'x5', 'x6

X_train, X_test = train_test_split(df, test_size=0.2, random_state=42)
```

Побудова дерева рішень

In [3]:

```
class Tree:
    def __init__(self, parent=None):
        self.parent = parent
        self.children = []
        self.splitFeature = None
        self.splitFeatureValue = None
        self.label = None
```

In [4]:

```
def dataToDistribution(data):
    ''' Функція перетворює набір даних, який має n можливих
        класифікаційних міток, в розподіл ймовірностей з n записами. '''

    allLabels = [label for (point, label) in data]
    numEntries = len(allLabels)
    possibleLabels = set(allLabels)
    dist= []
    for aLabel in possibleLabels:
        dist.append(float(allLabels.count(aLabel)) / numEntries)
    return dist
```

In [5]:

```
def entropy(dist):
    ''' Функція обчислює ентропію Шеннона для заданого розподілу ймовірностей. '''
    return -sum([p * math.log(p, 2) for p in dist])
```

In [6]:

```
def splitData(data, featureIndex):
    ''' Функція виконує ітерацію над підмножинами даних,
        що відповідають кожному значенню функції в індексі featureIndex.'''

    # отримання можливих значень заданої ознаки
    attrValues= [point[featureIndex] for (point, label) in data]
    for aValue in set(attrValues):
        # обчислення частини розбиття, що відповідає обраному значенню
        dataSubset= [(point, label) for (point, label) in data if point[featureIndex] =
        yield dataSubset
```

In [7]:

```
def gain(data, featureIndex):
    ''' Функція обчислює очікуваний приріст інформації від
        розбиття даних на всі можливі значення функції '''

    entropyGain = entropy(dataToDistribution(data))
    for dataSubset in splitData(data, featureIndex):
        entropyGain -= entropy(dataToDistribution(dataSubset))
    return entropyGain
```

In [8]:

```
def homogeneous(data):
    ''' Функція повертає True, якщо дані мають однакову мітку,
        і False в іншому випадку '''
    return len(set([label for (point, label) in data])) <= 1
```

In [9]:

```
def majorityVote(data, node):
    ''' Функція повертає вузол мітки з більшістю міток класу в даному наборі даних '''

    labels = [label for (point, label) in data]
    choice = max(set(labels), key=labels.count)
    node.label= choice
    return node
```

In [10]:

```
def buildDecisionTree(data, root, remainingFeatures, max_depth):
    ''' Функція будує дерево рішень з даних даних,
        додаючи дітей до кореневого вузла (який може бути піддеревом) '''

    # Глобальна змінна, яка позначає поточну глибину дерева
    global current_depth

    # Зупиняємось, якщо поточна глибина більша за максимально допустиму глибину дерева
    if current_depth >= max_depth:
        remainingFeatures = []

    # Якщо всі елементи мають однаковий клас, то класифікуємо листок дерева міткою цьо
    if homogeneous(data):
        root.label= data[0][1]
        root.classCounts = {root.label: len(data)}
        return root

    # Якщо немає більше ознак для подальшого розбиття,
    # то класифікуємо листок дерева міткою класу якого більшість
    if len(remainingFeatures) == 0:
        return majorityVote(data, root)

    # Знаходження індексу найкращої функції для поділу
    bestFeature= max(remainingFeatures, key=lambda index: gain(data, index))
    # Якщо приріст інформації дорівнює нулю,
    # то класифікуємо листок дерева міткою класу якого більшість
    if gain(data, bestFeature) == 0:
        return majorityVote(data, root)

    root.splitFeature = bestFeature

    #Додавання дочірніх вузлів для вже існуючих
    for dataSubset in splitData(data, bestFeature):
        aChild = Tree(parent=root)
        aChild.splitFeatureValue = dataSubset[0][0][bestFeature]
        root.children.append(aChild)

        #Запуск рекурсивного процесу, де дочірні вузли виступають в якості батьківськ
        buildDecisionTree(dataSubset, aChild, remainingFeatures - set([bestFeature]), r

    current_depth += 1

    return root
```

In [11]:

```
def decisionTree(data, max_depth):
    ''' Функція повертає збудоване дерево '''
    return buildDecisionTree(data, Tree(), set(range(len(data[0][0]))), max_depth)
```

In [12]:

```
def classify(tree, point):
    ''' Функція класифікаці даних шляхом проходження даного дерева рішень. '''
    if tree.children== []:
        return tree.label
    else:
        matchingChildren = []
        for child in tree.children:
            if child.splitFeatureValue == point[tree.splitFeature]:
                matchingChildren.append(child)

        try:
            return classify(matchingChildren[0], point)
        except Exception:
            return child.label
```

Оцінювання якості збудованого дерева

In [13]:

```
train_data = [(x[:-1], x[-1]) for x in X_train.values.tolist()]
test_data = [(x[:-1], x[-1]) for x in X_test.values.tolist()]

y_train = np.array([label for point, label in train_data])
y_test = np.array([label for point, label in test_data])

for max_depth in range(2, 11):
    current_depth = 0
    tree = decisionTree(train_data, max_depth=max_depth)

    y_predicted_train = [classify(tree, point) for point, label in train_data]
    y_predicted_test = [classify(tree, point) for point, label in test_data]

    accuracy_test = (y_predicted_test == y_test).mean()
    accuracy_train = (y_predicted_train == y_train).mean()

    print('============= max_depth -', max_depth, '=============')
    print('Train accuracy:',np.round(accuracy_train*100,2),'%')
    print('Test accuracy:',accuracy_test*100,'%')
    print('')
```

```
============= max_depth - 2 =============
Train accuracy: 44.23 %
Test accuracy: 23.076923076923077 %

============= max_depth - 3 =============
Train accuracy: 44.23 %
Test accuracy: 23.076923076923077 %

============= max_depth - 4 =============
Train accuracy: 44.23 %
Test accuracy: 23.076923076923077 %

============= max_depth - 5 =============
Train accuracy: 44.23 %
Test accuracy: 23.076923076923077 %

============= max_depth - 6 =============
Train accuracy: 46.15 %
Test accuracy: 15.384615384615385 %

============= max_depth - 7 =============
Train accuracy: 46.15 %
Test accuracy: 15.384615384615385 %

============= max_depth - 8 =============
Train accuracy: 57.69 %
Test accuracy: 0.0 %

============= max_depth - 9 =============
Train accuracy: 63.46 %
Test accuracy: 0.0 %

============= max_depth - 10 =============
Train accuracy: 63.46 %
Test accuracy: 0.0 %
```

Отже, при глибині дерева 2, 3, 4 або 5 воно найкраще класифікує відкладену вибірку

In [14]:

```
train_data = [(x[:-1], x[-1]) for x in X_train.values.tolist()]
test_data = [(x[:-1], x[-1]) for x in X_test.values.tolist()]

y_train = np.array([label for point, label in train_data])
y_test = np.array([label for point, label in test_data])

current_depth = 0
tree = decisionTree(train_data, max_depth=4)

y_predicted_train = [classify(tree, point) for point, label in train_data]
y_predicted_test = [classify(tree, point) for point, label in test_data]
```

In [15]:

```
x = np.arange(len(y_test))
width = 0.3

fig, ax = plt.subplots(figsize=(10,6))
ax.bar(x - width/2, y_test, width, label='true labels')
ax.bar(x + width/2, y_predicted_test, width, label='predicted labels')

ax.set_ylabel('Class label')
ax.set_xticks(x)
ax.legend()
plt.show()
```

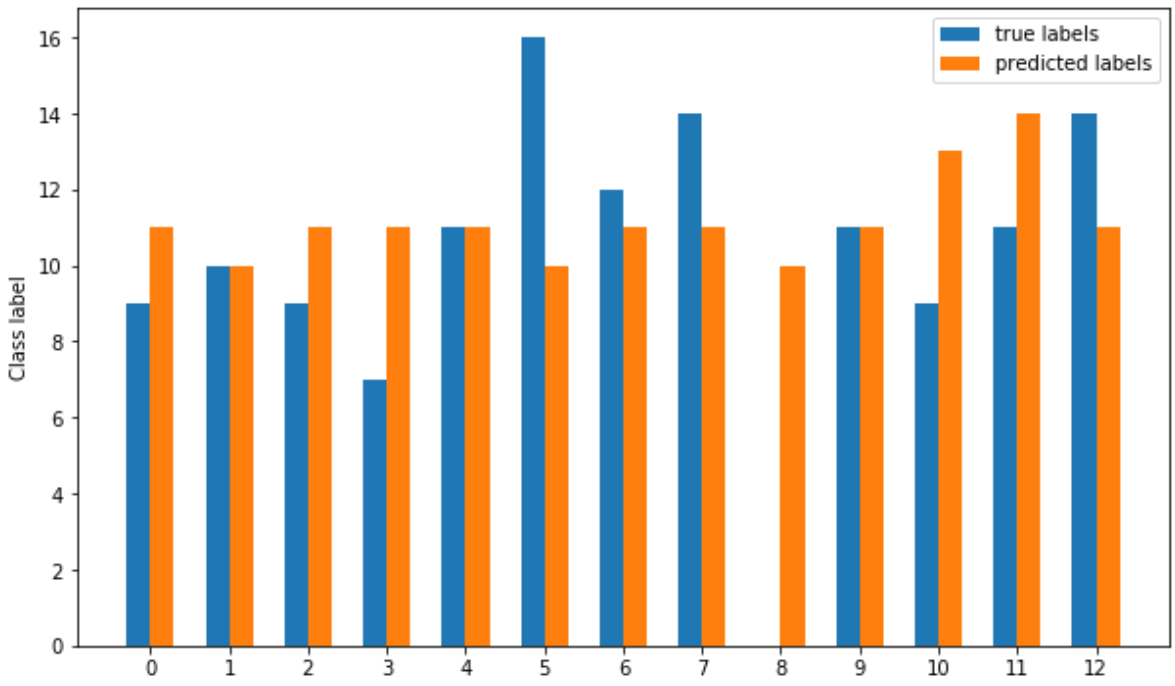

Метод KNN

In [16]:

```
x_train = X_train[X_train.columns[0:-1]].values
y_train = X_train[X_train.columns[-1]].values
x_test = X_test[X_test.columns[0:-1]].values
y_test = X_test[X_test.columns[-1]].values
```

In [17]:

```
def compute_distances(x_known, x_unknown):

    num_pred = x_unknown.shape[0]
    num_data = x_known.shape[0]

    dists = np.zeros((num_pred, num_data))

    for i in range(num_pred):
        for j in range(num_data):
            dists[i,j] = np.sum(x_known[j] == x_unknown[i])

    return dists
```

In [18]:

```
def k_nearest_labels(dists, y_known, k):

    num_pred = dists.shape[0]
    n_nearest = []

    for j in range(num_pred):
        dst = dists[j]
        closest_y = y_known[np.argpartition(dst, k-1)[:k]]

        n_nearest.append(closest_y)

    return np.asarray(n_nearest)
```

In [19]:

```
class KNearest_Neighbours:

    def __init__(self, k):
        self.k = k
        self.test_set_x = None
        self.train_set_x = None
        self.train_set_y = None


    def fit(self, train_set_x, train_set_y):
        self.train_set_x = train_set_x
        self.train_set_y = train_set_y

    def predict(self, test_set_x):

        y_labels = k_nearest_labels(compute_distances(self.train_set_x, test_set_x), s
        y_predictions = []
        for i in range(y_labels.shape[0]):
            bc = np.bincount(y_labels[i])
            y_predictions.append(np.arange(len(bc))[bc == bc.max()].min())

        return y_predictions
```

In [20]:

```
for k in range(1, 10, 2):
    knn = KNearest_Neighbours(k)
    knn.fit(x_train, y_train)
    y_pred_knn = knn.predict(x_test)
    accuracy = (y_pred_knn == y_test).mean() * 100
    print("k = {}; accuracy = {}%".format(k, accuracy))
```

```
k = 1; accuracy = 7.6923076923076925%
k = 3; accuracy = 15.384615384615385%
k = 5; accuracy = 15.384615384615385%
k = 7; accuracy = 15.384615384615385%
k = 9; accuracy = 7.6923076923076925%
```

З даних результатів видно, що для даного набору даних кількість сусідів, при якій алгоритм дає найбільшу точність, дорівнює 3, 5 або 7. Гірша точність при K = 1 або 9.

In [21]:

```
knn = KNearest_Neighbours(5)
knn.fit(x_train, y_train)
y_pred_knn = knn.predict(x_test)
```

In [22]:

```
print("К найближчих сусідів:    ",y_pred_knn)
print("Дерева прийняття рішень: ",y_predicted_test)
```

```
К найближчих сусідів:     [10, 10, 10, 10, 13, 10, 13, 8, 10, 13, 9, 9, 10]
Дерева прийняття рішень:  [11, 10, 11, 11, 11, 10, 11, 11, 10, 11, 13, 14, 1
1]
```

In [23]:

```
print("Кількість однаково спрогнозованих значень двома методами: ",sum(np.array(y_pred
```

```
Кількість однаково спрогнозованих значень двома методами:  3
```

Висновки

1) Було реалізовано два методи класифікації: дерево прийняття рішень та KNN

2) В ході роботи було встановлено, що дерево прийняття рішень дає кращий результат на відкладеній вибірці, ніж KNN